MiniCPM5-2B 推理吞吐优化

团队：prince22466 | 模型：MiniCPM5-2B | 框架：FlagOS / vLLM-FL | 平台：天数 BI-V150

1. 测试结果与效果分析

官方 full-run：输入 4096 / 16384 tokens，输出 1024 tokens，并发 64，请求数分别为 256 / 128。每场景 4 次全部成功，官方脚本 SKIP_FIRST=1，以下采用后三次的汇总值。基线为历史自测第一组 full-run 汇总，并非同一时段重测。

场景	基线 (tok/s)	v13 (tok/s)	绝对增益	相对增益
4K	1881.95	2752.60	+870.65	+46.26%
16K	861.88	1890.18	+1028.30	+119.31%

指标	4K 基线 → v13	16K 基线 → v13
Mean TTFT (ms)	12309.34 → 5651.44	636512.47 → 270913.54
Mean TPOT (ms)	156.12 → 110.08	518.00 → 241.94
Output tok/s	376.39 → 550.52	50.70 → 111.19

精度：v13 profiling/summary.txt 记录 math_500 eval >=0.95: True，按赛事 MATH-500 Level 3 口径达到 95% 门槛；未附具体准确率、逐题结果或完整评测日志，不将 v10 的 97.1% 作为 v13 成绩。

Half-run（仅内部参考，不作为正式成绩）：v13 4K/16K 为 2418.05/1853.56 tok/s，v10 为 2372.38/1872.70 tok/s，分别变化 +1.93%/-1.02%。未做同机同批次配对复测，不能证明重构带来增益或统计等价。

16K 吞吐提升最大，TTFT 与 TPOT 同时改善；但未进行 v13 单项消融或 GPU 时间占比测量，不能将全部端到端增益归因于某一项优化。历史基线 CSV 另含第二组未标注汇总（1974.86/888.16 tok/s），未混用。

2. 方案设计与算法原理

瓶颈：长序列 Prefill 的 GQA 分块对 KV Tile 复用不足；Decode 重复加载同一物理页索引。长上下文服务还受 KV Cache 容量、排队、抢占和混合批次干扰影响。

标准注意力 O = softmax(QK^T / sqrt(d) + M)V；GQA 16 个 Q Head、2 个 KV Head、Head Dim=128，每个 KV Head 对应 8 个 Q Head。逻辑位置 t 的物理页为 BlockTable[floor(t/B)]，页内偏移为 t mod B。保持因果掩码、全量注意力和分页映射语义，不改变模型权重。

Prefill：增加 Query 分块与 KV Tile 复用

参数	v0	v13（满足条件）
BLOCK_M	16	64
BLOCK_Q = BLOCK_M / 8	2	8
num_stages	Triton 默认	2

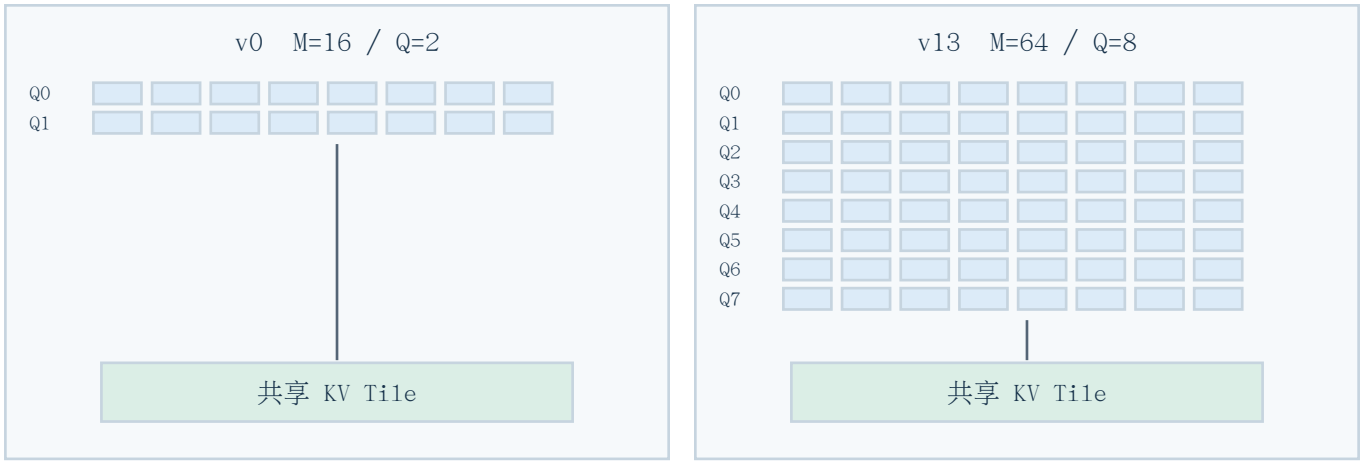


图 1 单个 KV Head 的 Query 分块与 KV Tile 复用（每行 8 个 Q Head）

同一 KV Tile 服务 8 而非 2 个 Query 位置，理论复用位置数扩大 4 倍；这并非实测带宽或吞吐加速比。适用于 max_seqlen_q>1（含符合条件的混合批次）、BF16 Q/K/V、16Q/2KV、head_size=128、非量化 KV、因果注意力、无 Tensor Descriptor。排除逐序列因果、Sliding Window、Chunk Lookback、多模态前缀、ALiBi、QQ Bias、Sink、Soft Cap、输出量化；不满足条件保留原有通用配置。

3. Decode：分页 KV 索引复用

DECODE_PAGE_LOOKUP 为编译期特化，仅在 max_seqlen_q=1、BF16 Q/K/V、16Q/2KV、head_size=128、非量化 KV、无 Tensor Descriptor、页大小为正的 2 次幂且页和 Tile 大小互为整除时启用。

以 16-token KV 页为例：2D Decode 的 32-token Tile 加载两个物理页索引，再以 t1.gather 分配给各 Lane；3D Segmented Decode 的 16-token Tile 加载一个索引并广播。末尾多页 Tile 的页表加载保留有效页掩码；K/V 读取保留原有 Token 掩码和页内偏移。

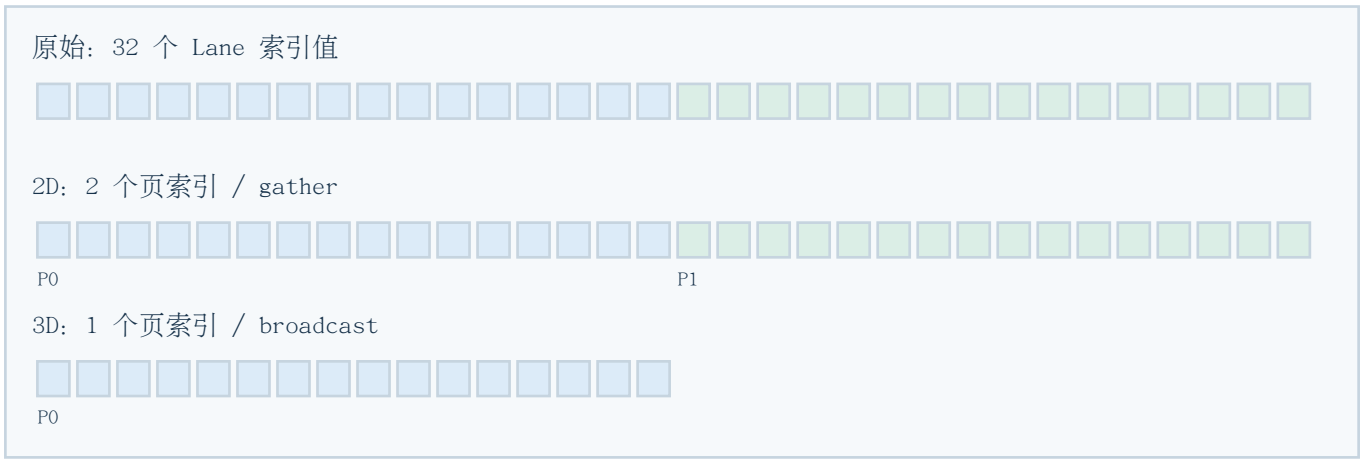


图 2 Decode 分页 KV 索引复用（16-token 页示例）

优化的是地址生成和索引加载，而非减少历史 Token 或 K/V 数据。原有 2D/3D 选择及分段 Softmax 归约不变。Prefill 与 Pure Decode 特化互斥；混合批次仅可进入 Prefill 特化。不满足条件时保留逐 Token 页表查询路径。

4. 实现架构、验证与合规

v13 是 v10 的设备无关重构，统一算子文件与 v10 内容一致；对 v0 的源码树比较表明 FlagGems 与 benchmark 脚本均未改变，仅 v11m-plugin-FL 有生产代码改动。

vLLM → PlatformFL.get_attn_backend_cls → 原有 call_op("attention_backend") → 仅当选中 stock dense Triton 且非 MLA / sparse 时，映射到 OptimizedTritonAttentionBackend → OptimizedTritonAttentionImpl.forward → unified_attention。其他选中路径原样返回（含 FlagGems、自定义后端），没有 GPU 厂商判断。设备无关指代码选择无厂商门控，并不代表其他 GPU 已验证。

核心文件（相对于 v11m-plugin-FL/）：

- v11m_fl/platform.py：保留原 dispatch 后特化 stock dense Triton。

- v11m_fl/dispatch/backends/triton_attention.py：继承原 Triton Backend/Impl，复用 metadata、KV Cache 更新和接口。

- v11m_fl/dispatch/backends/triton_unified_attention.py：统一 kernel 与两项算子特化，保留原计算和回退。

测试文件（tests/functional_tests/）：test_biv150_attention.py、test_biv150_decode.py、test_biv150_mixed_paging.py。覆盖 dispatch、回退、BF16 GQA、2D/3D Decode、混合批次及分页正确性。文件名是历史命名，不构成设备门控；本报告不宣称已有 v13 GPU pytest 日志。

历史 BI-V150 环境记录：单卡 32 GiB；Ubuntu 24.04.2、Python 3.12.11、vLLM 0.24.0+empty、v11m-plugin-fl 0.3.0rc0+gl3eb9be69、FlagGems 5.3.5、FlagTree 0.6.2a3+iluvatar3.6、PyTorch 2.10.0+corex.4.5.0、Transformers 5.14.1、EvalScope 1.11.1。部署与完整运行命令见 readme.md。沐曦 C500 未完成性能验证。

赛事合规：未通过超参数开启量化/投机采样，未调优官方 benchmark，未删除主要算子选择逻辑或切换至无优化算子，未直接合并新版 FlagOS。优化限于已有 Triton 注意力的分块与分页索引；不裁剪注意力范围。

证据（仓库 Co_Kaggle/g7/tests_BI-V150/）：Optimization/v13；profiling/v13/{4k16k_rawruns.csv,4k16k_summary.csv,summary.txt}；4k16K_summary_benchmark.csv；4k16K_rawrun_benchmark.csv；HW_SW_info.txt；FlagOS_Env.txt；math_500_eval_benchmark.txt（历史环境与命令）。